

VLA 모델의 국소 미세조정을 이용한 이기종 로봇팔 궤적 예측 및 ROS 기반 제어

하유빈[○], 최인엽^{*}

[○]강남대학교 컴퓨터공학과,

^{*}강남대학교 컴퓨터공학과

e-mail: gkdbqls889@kangnam.ac.kr[○], billychoi@kangnam.ac.kr^{*}

Trajectory Prediction and ROS-based Control for Heterogeneous Robot Arm via Local Fine-Tuning of VLA Model

Yubeen Ha[○], Inyeop Choi^{*}

[○]Dept. of Computer Engineering, Kangnam University,

^{*}Dept. of Computer Engineering, Kangnam University

● 요약 ●

본 논문은 Pi-Zero Vision-Language-Action(VLA) 모델을 사전학습 데이터에 포함되지 않은 6-DoF 이기종 로봇팔 Magician E6에 적용하기 위한 파라미터 효율 미세조정 및 ROS 기반 실시간 제어 방법을 제안한다. 제안한 방법으로 학습된 모델을 NVIDIA Jetson AGX 플랫폼에 탑재하여, ROS executor 기반 action chunk 제어 구조를 통해 Magician E6 로봇팔을 제어하도록 하였다. 실험 결과 제안한 방법은 사전 학습 객체와 신규 객체, 색상을 정확하게 식별하고 Pick-and-Place 태스크가 정상적으로 작동함을 보였다. 이를 통해 본 연구는 VLA 모델의 로봇 플랫폼 일반화 가능성을 검증하였으며, ROS executor 기반 action chunk 제어 구조를 제안하여 임베디드 환경에서의 실시간 Physical AI 구현 가능성을 입증하였다.

키워드: VLA Model, Pi-Zero, PEFT, LoRA, Robot Manipulation, ROS

I. Introduction

최근 인공지능 분야에서는 시각 정보 인지, 자연어 이해, 물리적 행동 제어를 단일 신경망으로 통합하는 Vision-Language-Action(VLA) 멀티모달 모델 연구가 빠르게 발전하고 있다. 기존 로봇 제어 파이프라인은 객체 검출(Object Detection), 포즈 추정(Pose Estimation), 모션 플래닝(Motion Planning) 등의 개별 모듈로 구성되는 경우가 많으며, 이 과정에서 연산 지연과 오차 누적 문제가 발생할 수 있다. 반면 VLA 모델은 입력 이미지와 자연어 명령을 바탕으로 end-to-end 방식의 로봇 행동을 생성함으로써, 기존 분리형 제어 구조보다 높은 유연성과 지능적 작업 수행 가능성을 보여준다.

오픈소스 기반 경량형 VLA 모델인 Pi-Zero는 대규모 멀티모달 정렬 학습을 통해 높은 open-domain 일반화 성능을 가지며, 직접 경험하지 못한 비정형 환경이나 유사 객체에 대해서도 zero-shot 및 few-shot 수준의 적응 가능성을 보인다. 이러한 특성은 자연어 명령 기반 객체 선택, 색상 및 형태 기반 조작, 새로운 작업 환경에 대한 일반화 가능성을 제공한다는 점에서 로봇 조작 분야에 중요한 의미를 가진다.

그러나 사전학습 단계에서 고려되지 않은 이기종 로봇팔에 VLA 모델을 그대로 적용하는 데에는 여전히 기술적 장벽이 존재한다. Pi-Zero가 사전학습 과정에서 경험한 로봇과 실제 적용 대상 로봇팔의 기하학적 구조, 관절 구성, 제어 공간이 다를 경우, 모델이 생성한 행동 표현을 실제 로봇 제어 명령으로 직접 연결하기 어렵다. 본 연구에서 사용하는 6-DoF Magician E6 로봇팔 역시 사전학습 로봇과 링크 구조, 관절 가동 범위, 기구학적 특성, action representation, 제어 주기 등이 다르며, 이러한 차이는 embodiment gap 또는 domain gap으로 작용하여 실제 물리 로봇 배포 시 성능 저하와 제어 불안정성을 유발할 수 있다.

이러한 문제를 해결하기 위해 전체 모델의 가중치를 업데이트하는 full fine-tuning을 적용할 수 있으나, 대규모 VLA 모델에서는 많은 GPU 메모리와 학습 시간이 요구되며 임베디드 edge computing 환경에서 Out-of-Memory(OOM) 문제가 발생할 수 있다. 또한 전체 모델 재학습은 Pi-Zero가 사전학습을 통해 획득한 시각-언어 일반화 지식을 손상시키는 catastrophic forgetting을 유발할 수 있다. 따라서 사전학습된 VLA 모델의 일반화 능력을 유지하면서 새로운 로봇

플랫폼과 작업공간에 적응하기 위해서는 필요한 모듈만 선택적으로 조정하는 parameter-efficient fine-tuning 전략이 필요하다.

본 논문에서는 Pi-Zero VLA 모델의 일반화 성능을 보존하면서, 사전학습 데이터에 포함되지 않은 Magician E6 로봇팔의 관절 궤적을 예측하고 ROS 기반으로 실시간 제어할 수 있는 parameter-efficient transfer learning 구조를 제안한다. 제안하는 시스템은 NVIDIA Jetson AGX 64GB edge platform에 Pi-Zero VLA 모델을 탑재하고, dual camera 환경에서 수집한 총 180개 episode, 72,000 frame의 시각-행동 데이터셋을 이용하여 학습을 수행한다. 또한 LLM backbone은 동결하고, vision encoder의 18~26번 high-level block만 Low-Rank Adaptation(LoRA) 방식으로 미세조정하여 사전학습된 시각-언어 일반화 지식의 손상을 최소화하면서 새로운 작업공간에 적응하도록 하였다.

II. Preliminaries

1. Related works

최근 로봇 조작 분야에서는 시각 관측, 자연어 명령, 행동 생성을 하나의 정책 모델로 통합하는 VLA 모델과 로봇 파운데이션 모델 연구가 활발히 진행되고 있다. RT-1과 RT-2는 대규모 로봇 데이터와 vision-language model의 의미 지식을 활용하여 다양한 객체와 언어 명령에 대한 일반화 가능성을 보였다[1], [2]. 또한 Open X-Embodiment, Octo, OpenVLA는 cross-robot policy 학습과 새로운 센서 및 행동 공간에 대한 fine-tuning 가능성을 제시하였다[3]-[5].

Pi-Zero는 pre-trained vision-language model 위에 flow matching 기반 action generation 구조를 결합한 VLA 모델로, 언어 명령 기반 조작과 새로운 skill fine-tuning 가능성을 가진다[6]. 그러나 사전학습 데이터에 포함되지 않은 로봇팔에 직접 적용할 경우 링크 구조, 관절 범위, 제어 주기, action representation 차이로 인해 embodiment gap이 발생한다. 이를 완화하기 위해 LoRA와 같은 parameter-efficient fine-tuning 기법을 사용할 수 있으며[7], 최근 VLA fine-tuning 연구에서도 LoRA, action chunking, continuous action representation 등이 효율적인 로봇 적응 방법으로 제시되고 있다[8]-[10]. 본 연구는 이러한 흐름을 바탕으로 Pi-Zero VLA 모델을 6-DoF Magician E6 로봇팔에 로컬 fine-tuning하고, ROS 기반 실시간 제어 구조를 통해 실제 물리 로봇팔에 배포한다.

III. The Proposed Scheme

본 논문에서 제안하는 시스템은 Pi-Zero VLA 모델의 시각-언어 일반화 능력을 유지하면서, 사전학습 데이터에 포함되지 않은 이기종 로봇팔의 제어 궤적을 학습하고 실제 로봇 제어 명령으로 실행하는 것을 목표로 한다. 이를 위해 LLM backbone 동결, vision encoder high-level block의 LoRA fine-tuning, Action Expert 학습, dual camera 기반 데이터셋 구축, ROS executor 기반 실시간 제어 구조를 결합한다.

3.1 Local LoRA Fine-tuning and Action Expert Training

Pi-Zero VLA 모델의 일반화 성능은 텍스트 명령과 시각적 특징을 정렬하는 LLM backbone에 기반한다. 본 연구에서는 LLM backbone을 동결하여 연산 효율성을 확보하고 파괴적 망각(catastrophic forgetting)을 방지한다. 대신 Magician E6 로봇팔과 dual camera 작업공간에 필요한 시각적 의미 정보를 반영하기 위해 vision encoder의 18~26번 high-level block만 LoRA 방식으로 미세조정한다.

Action Expert는 VLM이 추출한 시각-언어 문맥 정보와 로봇의 현재 관절 상태를 입력으로 받아 연속적인 action chunk를 예측한다. Pi-Zero 계열 모델은 행동을 이산 토큰이 아닌 연속 벡터로 다루며, flow matching 기반 학습을 통해 실제 로봇 데모 데이터의 action 분포로 이동하는 벡터장을 학습한다. 이를 통해 단일 step이 아닌 미래 행동 묶음인 action chunk를 생성하여 연속적인 조작 궤적을 실행할 수 있다.

3.2 Dual Camera-Based Dataset Collection

단일 시점 카메라의 시야 가려짐을 완화하고 작업공간의 공간 정보를 안정적으로 확보하기 위해 dual camera 기반 데이터 수집 환경을 구성하였다.



Fig. 1. Data collection by dual camera

Pi-Zero VLA 모델에서 사용하지 않은 새로운 객체와 작업공간에 적응하기 위해 총 180개 episode의 로봇 조작 데이터를 수집하였다. 각 episode는 400 frame으로 구성되며, 전체 데이터셋은 총 72,000 frame의 시각-행동 데이터를 포함한다. 수집 데이터는 LeRobot 포맷으로 구성되며, 각 timestep은 두 대의 224×224 RGB 카메라 이미지, 7차원 state, 7차원 action, task index, timestamp 정보를 포함한다. 여기서 state는 6개 관절 상태와 gripper 상태, action은 6개 관절 축의 속도 delta와 gripper 절대 상태로 정의된다.

3.3 ROS-based Real-time Control Pipeline

학습된 Pi-Zero VLA 모델은 NVIDIA Jetson AGX 보드에서 별도의 policy server로 실행되며, ROS2 파이프라인과 WebSocket 방식으로 연결된다. 전체 제어 구조는 Fig. 2와 같이 dual camera 입력, 로봇 상태 피드백, phase 기반 프롬프트 생성, 정책 추론, action chunk 실행 단계로 구성된다.

구현 단계에서 ROS2 파이프라인은 camera_state_node, task_node, inference_bridge_node, executor_supervisor_node로 구성된다. camera_state_node는 HIK 및 ZED 카메라 이미지와 로봇 관절 상태를 발행하고, task_node는 gripper 상태와 tcp_z 정보를 기반으로 approach, grasp, lift, transport, place, release 단계의 phase 기반 프롬프트를 생성한다. inference_bridge_node는 dual camera 이미지, 로봇 상태, 프롬프트를 하나의 observation으로 조립하여 Pi-Zero VLA policy server에 추론을 요청한다.

Pi-Zero VLA policy server는 VLM 모듈을 통해 시각-언어 context embedding을 생성하고, Action Expert는 이 정보와 현재 관절 상태를 입력으로 받아 16×7 action chunk를 예측한다. 예측된 action chunk는 ROS2 파이프라인으로 반환되며, executor_supervisor_node는 이를 16 Hz의 고정 제어 주기로 소비하여 Magician E6 로봇팔에 관절 명령을 전송한다. 본 연구에서는 동일한 action chunk에 대해 ServoJ와 MovJ 제어 모드를 비교하여, VLA 기반 조작에서 실시간 실행 방식에 따른 제어 성능을 평가한다.




Fig. 2. ROS-based real-time control pipeline.

제안된 시스템은 듀얼 카메라 센싱, ROS2 기반 관찰 어셈블리, Pi-Zero VLA 정책 서버 및 관절 공간 동작 체크 실행을 위한 실행기 노드로 구성된다. 정책 서버는 16×7 동작 체크를 예측하고, 실행기는 ServoJ 또는 MovJ 모드를 사용하여 16Hz의 고정 제어 속도로 생성된 동작을 실행한다.

IV. Experimental Results

제안한 Pi-Zero VLA 기반 제어 방법의 성능을 검증하기 위해 객체 인식, 색상 조건 인식, Pick-and-Place, ServoJ/MovJ 제어 모드 비교 실험을 수행하였다. Fig. 3은 객체 인식 및 색상 조건 실험에 사용된 테스트 객체를 나타낸다. 실험 결과, 사전학습 객체인 계란, 이문드, 충전기와 신규 객체인 박스에 대해 단일 객체 조건에서는 모두 100%의 조작 성공률을 보였다. 다중 객체 조건에서는 계란과 충전기에 대해 높은 성공률을 보였으나, 이문드는 계란과 형태가 유사하여 낮은 성공률을 나타냈다. 또한 동일한 형태의 색상 객체에

대해서는 빨강, 파랑, 노랑, 초록 모두 20회 실험에서 100% 성공률을 보였다. Pick-and-Place 태스크는 20회 중 18회 성공하였으며, ServoJ는 MovJ보다 빠른 픽 완료 시간과 낮은 명령 RTT를 보여 VLA가 생성한 action chunk를 실시간으로 실행하는 데 더 적합함을 확인하였다.




Fig. 3. Test Objects and Color Targets

V. Conclusions

본 논문에서는 Pi-Zero VLA 모델을 사전학습 데이터에 포함되지 않은 6-DoF Magician E6 로봇팔에 적용하기 위한 parameter-efficient fine-tuning 및 ROS 기반 실시간 제어 방법을 제안하였다. 제안한 방법을 실제 로봇에 탑재하여 실험 결과 사전학습된 시각-언어 일반화 능력을 유지하면서 새로운 객체를 인식하고 설정한 태스크를 잘 수행하였다. 또한 ServoJ 제어 방식이 MovJ보다 실시간 action chunk 실행에 더 적합함을 확인하였다.

REFERENCES

- [1] A. Brohan et al., "RT-1: Robotics Transformer for Real-World Control at Scale," arXiv preprint arXiv:2212.06817, 2022.
- [2] A. Brohan et al., "RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control," arXiv preprint arXiv:2307.15818, 2023.
- [3] Open X-Embodiment Collaboration et al., "Open X-Embodiment: Robotic Learning Datasets and RT-X Models," arXiv preprint arXiv:2310.08864, 2023.
- [4] Octo Model Team et al., "Octo: An Open-Source Generalist Robot Policy," arXiv preprint arXiv:2405.12213, 2024.
- [5] M. J. Kim et al., "OpenVLA: An Open-Source Vision-Language-Action Model," arXiv preprint arXiv:2406.09246, 2024.
- [6] K. Black et al., "π0: A Vision-Language-Action Flow Model for General Robot Control," arXiv preprint arXiv:2410.24164, 2024.
- [7] E. J. Hu et al., "LoRA: Low-Rank Adaptation of Large

- Language Models,” arXiv preprint arXiv:2106.09685, 2021.
- [8] M. J. Kim, C. Finn, and P. Liang, “Fine-Tuning Vision-Language-Action Models: Optimizing Speed and Success,” arXiv preprint arXiv:2502.19645, 2025.
- [9] T. Z. Zhao, V. Kumar, S. Levine, and C. Finn, “Learning Fine-Grained Bimanual Manipulation with Low-Cost Hardware,” arXiv preprint arXiv:2304.13705, 2023.
- [10] C. Chi et al., “Diffusion Policy: Visuomotor Policy Learning via Action Diffusion,” arXiv preprint arXiv:2303.04137, 2023.